01. 편향-분산 트레이드오프 (Bias-Variance Tradeoff) 시뮬레이션

개요

항목	내용
파일명	`01_bias_variance_tradeoff.py`
주제	편향-분산 트레이드오프 시각화
참고 논문	Pedro Domingos (2012) "A Few Useful Things to Know About Machine Learning"
핵심 라이브러리	NumPy, Matplotlib, scikit-learn
생성 결과물	`01_model_fits.png`, `01_bias_variance_tradeoff.png`, `01_prediction_variability.png`

먼저 알아야 할 것: 머신러닝의 목표란?

머신러닝의 최종 목표는 **"아직 보지 못한 새로운 데이터"에 대해 정확하게 예측하는 것**이다. 이것을 **일반화(Generalization)** 라고 부른다.

여기서 많은 초보자가 빠지는 함정이 있다:

- "학습 데이터에서 100점을 맞으면 좋은 모델 아닌가요?" → **아니다!**
- 시험에 비유하면, 기출문제(학습 데이터)를 통째로 외운 학생은 기출에서는 만점을 받지만, 새로운 문제(테스트 데이터)에서는 크게 틀릴 수 있다.
- 반대로, 너무 대충 공부한 학생은 기출에서도, 새 문제에서도 잘 못 푼다.

이 코드는 바로 이 딜레마를 수학적으로 보여준다. "얼마나 열심히(복잡하게) 학습해야 최적인가?"라는 질문에 대한 답을 시각화한다.

이론적 배경: 편향과 분산이란?

일상 속 비유로 이해하기

과녁 맞추기를 상상해보자. 10번 활을 쏜다고 하면:

- **편향(Bias)이 높다** = 화살이 항상 과녁의 **왼쪽 아래**에 몰린다. 즉, **체계적으로 빗나가는 것**이다. 조준 자체가 잘못되어 있다.
- **분산(Variance)이 높다** = 화살이 매번 **사방팔방** 다른 곳에 꽂힌다. 즉, **일관성이 없는 것**이다. 조준은 맞지만 손이 떨린다.
- **좋은 사수** = 편향도 낮고 분산도 낮다. 화살이 항상 과녁 중심에 모인다.

상태	편향	분산	비유
이상적	낮음	낮음	매번 과녁 한가운데에 적중
과소적합	높음	낮음	항상 같은 곳에 맞지만, 과녁 중심이 아님
과적합	낮음	높음	평균적으로는 중심이지만, 매번 다른 곳에 맞음
최악	높음	높음	사방으로 흩어지면서 중심도 빗나감

머신러닝에서의 의미

이것을 머신러닝 모델에 대입하면:

- **편향(Bias)** = 모델이 **실제 패턴을 얼마나 잘 포착하는가**
- 편향이 높다 = 모델이 너무 단순해서 데이터의 진짜 패턴을 놓친다
- 예: 곡선 형태의 데이터를 직선으로 예측하려는 경우
- **분산(Variance)** = 모델이 **학습 데이터에 얼마나 민감한가**
- 분산이 높다 = 학습 데이터가 조금만 바뀌어도 예측이 완전히 달라진다
- 예: 데이터의 노이즈(잡음)까지 외워버리는 경우

수학적 표현

모델의 **기대 예측 오류(Expected Prediction Error)** 는 다음 세 가지로 분해된다:

$$E\left[(y-\hat{f}(x))^2\right] = \mathrm{Bias}^2(\hat{f}(x)) + \mathrm{Var}(\hat{f}(x)) + \sigma^2$$

각 항목을 쉽게 풀어 설명하면:

항목	수학 기호	쉬운 설명	줄일 수 있나?
편향²	$\mathrm{Bias}^2(\hat{f}(x))$	모델의 "평균 예측"이 정답에서 얼마나 떨어져 있나	모델을 복잡하게 만들면 줄어듦
분산	$\mathrm{Var}(\hat{f}(x))$	학습 데이터가 바뀔 때 예측이 얼마나 흔들리나	모델을 단순하게 만들면 줄어듦
비가약 오류	σ^2	데이터 자체의 노이즈 (줄일 수 없음)	불가능! 데이터의 한계

핵심 딜레마: 편향을 줄이려면 모델을 복잡하게 만들어야 하는데, 그러면 분산이 올라간다. 반대로 분산을 줄이려면 모델을 단순하게 해야 하는데, 그러면 편향이 올라간다. 이것이 바로 **트레이드오프(상충 관계)** 이다.

이 코드가 하는 일: 전체 그림

이 코드는 **다항 회귀(Polynomial Regression)** 를 사용하여 편향-분산 트레이드오프를 직접 실험한다.

다항 회귀란?

가장 단순한 회귀 모델은 직선($y = ax + b$)이다. 다항 회귀는 이를 확장하여 곡선을 그릴 수 있게 한다:

- **차수 1** (직선): $y = a_1 x + a_0$
- **차수 2** (포물선): $y = a_2 x^2 + a_1 x + a_0$
- **차수 3**: $y = a_3 x^3 + a_2 x^2 + a_1 x + a_0$
- **차수 15**: $y = a_{15} x^{15} + \cdots + a_1 x + a_0$

차수가 높을수록 모델이 더 복잡한 곡선을 그릴 수 있다. 이 코드에서는 차수를 1부터 15까지 변화시키면서 "어떤 차수가 최적인가?"를 실험한다.

실험 설계

1. **정답 함수**: $f(x) = \sin(1.5\pi x)$ — 우리가 맞추려는 실제 곡선
2. **학습 데이터**: 정답 함수에 **노이즈(잡음)** 를 더한 30개 점 — 현실에서는 데이터에 항상 측정 오차가 있다
3. **실험 반복**: 노이즈가 매번 다르므로, **200개의 서로 다른 학습 데이터셋**을 만들어 통계적으로 분석
4. **결과 비교**: 차수 1~15의 모델별로 편향², 분산, 총 오류를 계산

코드 상세 설명

---

1. 정답 함수 정의

```
def true_function(x):
    return np.sin(1.5 * np.pi * x)
```

- 이것은 우리가 알아내고 싶은 **"진짜 정답"** 이다
- 실제 세계에서는 이 정답을 모르지만, 시뮬레이션에서는 알고 있으므로 모델의 성능을 정확히 측정할 수 있다
- $\sin$ 함수는 곡선이므로, 직선 모델로는 완벽히 포착할 수 없다 → 이것이 편향의 원인이 된다

2. 합성 데이터 생성

```
def generate_data(n_samples=30, noise_std=0.3):
    X = np.sort(np.random.uniform(0, 1, n_samples))
    y = true_function(X) + np.random.normal(0, noise_std, n_samples)
    return X, y
```

이 함수가 하는 일을 단계별로 설명하면:

1. `np.random.uniform(0, 1, 30)` → 0과 1 사이에서 30개의 X값을 무작위로 뽑는다

2. `true_function(X)` → 각 X에 대한 "진짜 정답" y값을 계산한다
3. `+ np.random.normal(0, 0.3, 30)` → 정답에 **노이즈를 더한다** ($\sigma = 0.3$)

왜 노이즈를 더하나? 현실의 데이터는 항상 측정 오차, 미관측 변수 등으로 인해 완벽하지 않다. 예를 들어 키와 몸무게의 관계를 수집하면, 같은 키여도 사람마다 몸무게가 다르다. 이 "다름"이 바로 노이즈다.

핵심: 이 함수를 호출할 때마다 **다른 노이즈가 추가**되므로, 매번 조금씩 다른 데이터셋이 만들어진다. 이 특성을 이용하여 "다른 데이터로 학습하면 모델이 얼마나 달라지는가"(=분산)를 측정한다.

3. 편향-분산 계산 — 핵심 엔진

```
def compute_bias_variance(degrees, n_datasets=200, n_samples=30,
                          noise_std=0.3, n_test=100):
```

이 함수가 이 프로그램의 **핵심**이다. 동작 원리를 단계별로 설명한다:

[준비 단계]

- 테스트 포인트 100개를 고정한다 (`X_test = np.linspace(0, 1, 100)`)
- 이 포인트에서의 진짜 정답도 계산한다 (`y_true = sin(1.5π × X_test)`)

[각 다항식 차수에 대해 반복]

예를 들어 "차수 5"일 때:

1. 200개의 서로 다른 학습 데이터셋을 생성한다 (매번 다른 노이즈)
2. 각 데이터셋으로 차수 5의 다항 회귀 모델을 학습한다
3. 모든 모델이 동일한 테스트 포인트 100개에서 예측한다
4. 200개 모델의 예측값이 모인 배열(200 × 100)이 만들어진다

[계산]

- **편향²**: 200개 모델의 "평균 예측"과 "진짜 정답" 간의 차이를 제곱
- 직관: 여러 번 시도했을 때, **평균적으로 정답에서 얼마나 떨어져 있나?**
- **분산**: 200개 모델의 예측값이 서로 얼마나 흩어져 있는지
- 직관: 데이터가 바뀔 때마다 **예측이 얼마나 불안정한가?**
- **총 오류** = 편향² + 분산 + σ^2 (노이즈 분산 = 0.09)

4. 시각화 함수 3개

함수	생성 파일	보여주는 것
`plot_model_fits()`	`01_model_fits.png`	차수별 모델이 데이터에 어떻게 맞춰지는지
`plot_bias_variance_tradeoff()`	`01_bias_variance_tradeoff.png`	편향², 분산, 총 오류의 변화 그래프
`plot_prediction_variability()`	`01_prediction_variability.png`	같은 차수의 모델이 다른 데이터에서 얼마나 다르게 예측하는지

결과물 분석

결과 1: 다양한 복잡도의 모델 적합 결과

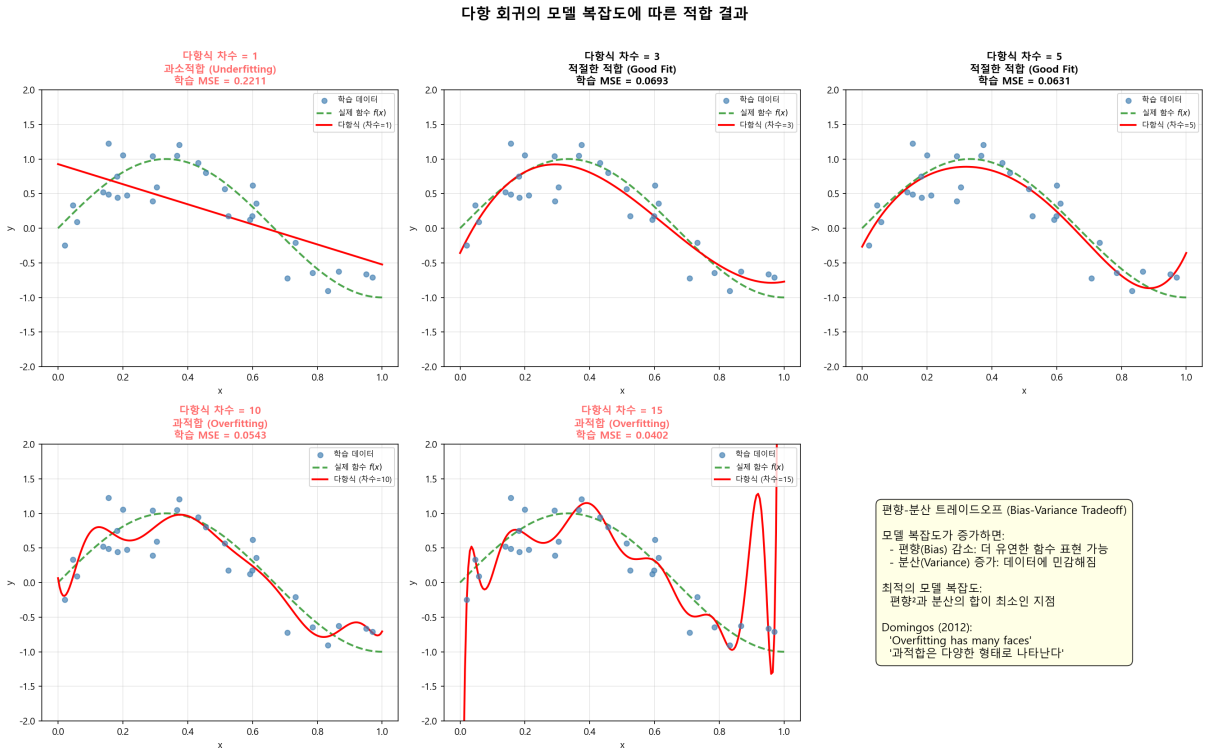

다항 회귀 모델 적합 결과

이 그림은 무엇을 보여주는가?

동일한 30개의 학습 데이터(파란 점)에 대해, 서로 다른 복잡도의 모델(빨간 선)을 적합시킨 결과이다. 녹색 점선이 우리가 맞추려는 "진짜 정답 함수"이다.

각 패널을 읽는 법:

차수 1 (직선) — 과소적합:

- 빨간 선이 직선이다. 사인 곡선은 직선이 아니므로, 아무리 잘 맞춰도 **직선으로는 곡선을 표현할 수 없다**
- 비유: 초등학교 수학만 배운 학생에게 미적분 문제를 풀라고 하는 것. 능력 자체가 부족
- 학습 MSE(오차)가 높다 = 학습 데이터에도 잘 맞지 않음

차수 3 — 적절한 적합에 근접:

- 곡선이 전체적인 형태를 따라가기 시작한다
- 아직 완벽하지는 않지만, 대략적인 패턴은 포착

차수 5 — 적절한 적합 (Good Fit):

- 빨간 선이 녹색 점선(정답)과 거의 일치!
- 데이터 포인트를 모두 통과하지는 않지만, **진짜 패턴을 잘 포착**하고 있다
- 비유: 핵심 개념을 잘 이해한 학생. 기출문제를 외우지 않았지만 새 문제도 잘 푼다

차수 10 — 과적합 시작:

- 데이터 포인트 사이에서 불필요한 진동(물결)이 나타난다
- 데이터의 노이즈(잡음)까지 학습하기 시작

차수 15 — 과적합:

- 모든 데이터 포인트를 거의 정확히 통과하지만, 데이터가 없는 구간에서 **심한 진동** 발생
- 비유: 기출문제를 통째로 외운 학생. 기출은 만점이지만, 조금만 변형된 문제가 나오면 크게 틀린다
- **학습 MSE는 매우 낮지만, 일반화 성능은 나쁘다** ← 이것이 과적합의 함정!

가장 중요한 교훈:

> 학습 오류(Training Error)가 낮다고 좋은 모델이 아니다! 차수 15는 학습 오류가 가장 낮지만, 새 데이터에는 최악의 모델이다. **테스트 오류(일반화 오류)가 진짜 중요하다.**

결과 2: 편향-분산 트레이드오프 곡선

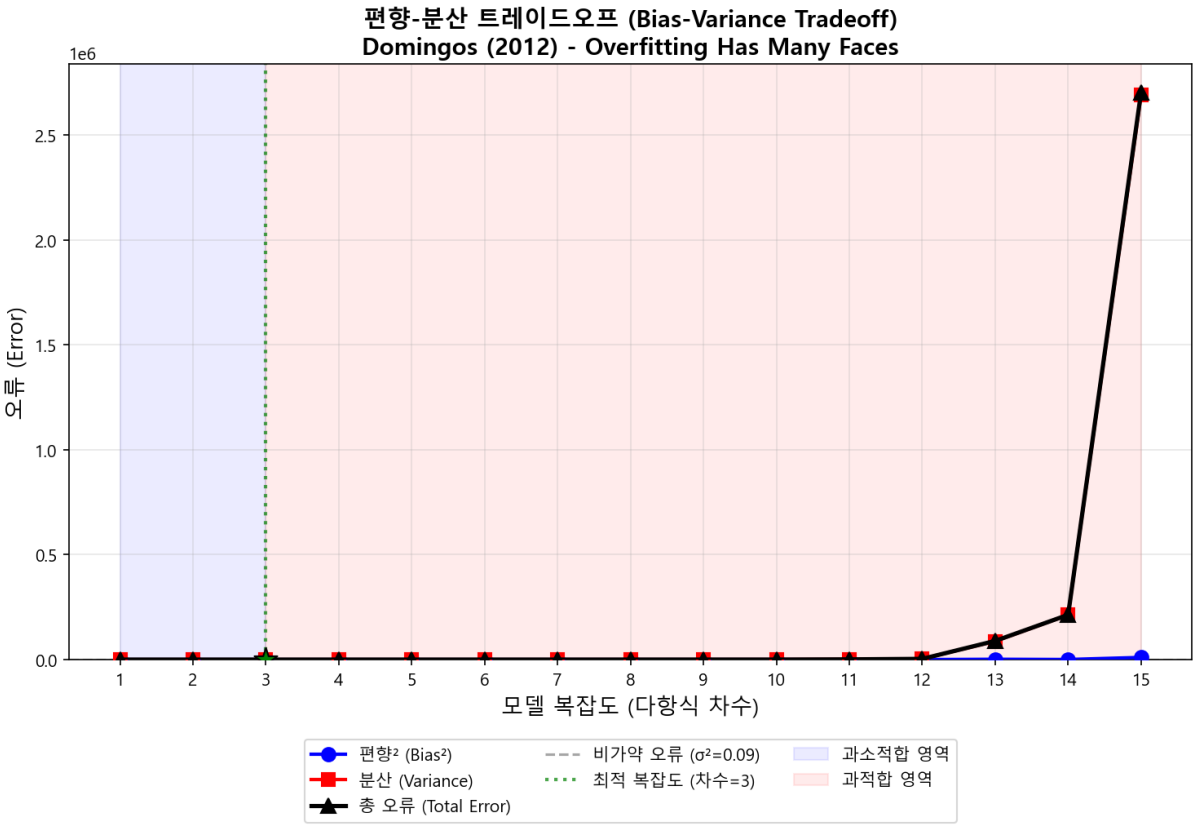

편향-분산 트레이드오프

이 그림은 무엇을 보여주는가?

이 그래프가 이 전체 실험의 **핵심 결과**이다. X축은 모델의 복잡도(다항식 차수), Y축은 오류 크기이다.

각 선의 의미:

파란선 (편향², Bias²) — "평균적으로 얼마나 빗나가는가":

- 차수가 1(직선)일 때 편향이 가장 높다 → 직선으로는 곡선 패턴을 포착할 수 없으니까
- 차수가 높아질수록 급격히 감소한다 → 복잡한 모델일수록 진짜 패턴에 가까워지니까
- 차수 5 이후에는 거의 0에 수렴 → 이미 충분히 복잡하므로 패턴을 포착

빨간선 (분산, Variance) — "데이터가 바뀌면 얼마나 흔들리는가":

- 차수가 낮을 때는 분산이 매우 낮다 → 단순한 모델은 어떤 데이터로 학습해도 비슷한 결과
- 차수가 높아질수록 점진적으로 증가 → 복잡한 모델은 데이터의 노이즈에 민감하게 반응
- 차수 10 이후 급격히 증가 → 노이즈까지 외워버리므로, 데이터가 달라지면 예측도 크게 달라짐

검은선 (총 오류, Total Error) — "실제 성능":

- 편향² + 분산 + 노이즈(0.09)의 합계
- **U자 형태**를 보인다! 이것이 핵심이다
- 왼쪽(낮은 차수)에서는 편향이 지배 → 총 오류가 높음
- 오른쪽(높은 차수)에서는 분산이 지배 → 총 오류가 높음
- **가운데(최적 차수)에서 총 오류가 최소** → 이것이 최적의 모델!

회색 점선 (비가약 오류, $\sigma^2 = 0.09$):

- 데이터 자체의 노이즈로 인한 오류
- 어떤 모델을 사용해도 이 선 아래로는 내려갈 수 없다
- "완벽한 모델도 0.09의 오류는 피할 수 없다"

영역 구분:

- **파란 영역 (왼쪽)**: 과소적합 영역 — 모델이 너무 단순해서 편향이 크다
- **빨간 영역 (오른쪽)**: 과적합 영역 — 모델이 너무 복잡해서 분산이 크다
- **초록 별표**: 편향과 분산이 **최적의 균형**을 이루는 지점 = **최적 모델**

결과 3: 예측 변동성 비교

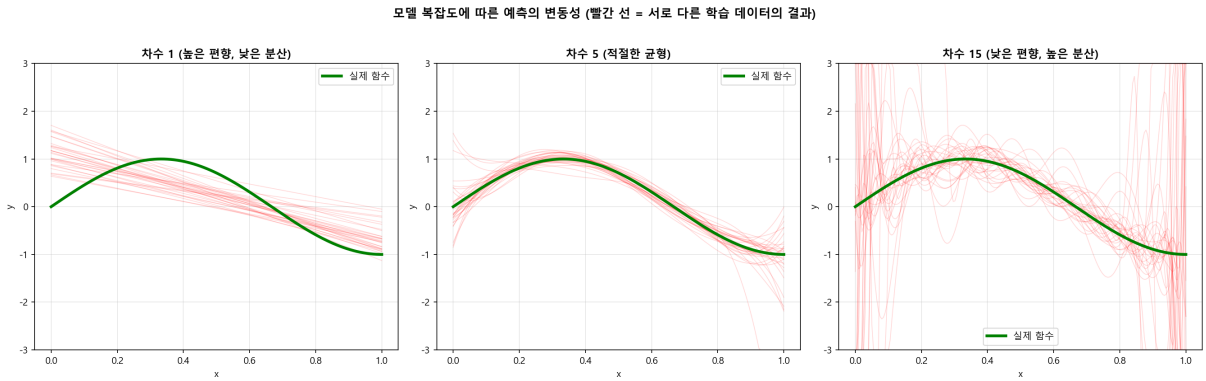

예측 변동성

이 그림은 무엇을 보여주는가?

"분산(Variance)"이 실제로 어떤 모습인지 **눈으로 확인**하는 그림이다. 30개의 서로 다른 학습 데이터셋으로 동일한 모델을 학습하고, 그 예측 결과(빨간 선)를 모두 겹쳐 그렸다. 녹색 선이 진짜 정답이다.

왼쪽 패널 — 차수 1 (높은 편향, 낮은 분산):

- 빨간 선들이 거의 한 줄로 모여 있다 → **분산이 낮다** (어떤 데이터로 학습해도 비슷한 결과)
- 하지만 녹색 정답과 크게 다르다 → **편향이 높다** (직선으로는 곡선을 표현 못함)
- 비유: 시험에서 항상 60점을 받는 학생. 일관적이지만 성적이 낮다

가운데 패널 — 차수 5 (적절한 균형):

- 빨간 선들이 녹색 정답 주위에 적당히 분포한다
- 각 선이 완벽히 같지는 않지만, 대체로 정답에 가깝다
- **편향과 분산이 모두 적절한 수준** → 이것이 최적!
- 비유: 시험에서 85~95점 사이를 받는 학생. 약간의 변동은 있지만 전반적으로 우수

오른쪽 패널 — 차수 15 (낮은 편향, 높은 분산):

- 빨간 선들이 **크게 흩어져 있다** → **분산이 매우 높다**
- 특히 데이터 양 끝(0과 1 근처)에서 예측이 극단적으로 달라진다
- 어떤 빨간 선은 정답에 가깝지만, 어떤 선은 완전히 빗나간다
- 비유: 시험에서 30점~100점을 오가는 학생. 때로는 만점이지만 들쭉날쭉

이 그림에서 배울 수 있는 핵심:

단순한 모델은 "안정적이지만 부정확"하고, 복잡한 모델은 "평균적으로는 정확하지만 불안정"하다. **우리가 원하는 것은 이 둘의 균형점**이다.

핵심 정리: 왜 이것이 중요한가?

Domingos (2012) 논문의 핵심 메시지

> "Overfitting has many faces" (과적합은 다양한 형태로 나타난다)

1. **학습 성능에 속지 마라**: 학습 데이터에서 100점이어도 새 데이터에서 50점일 수 있다
2. **모델 복잡도의 균형이 핵심**: 너무 단순하면 패턴을 놓치고, 너무 복잡하면 노이즈를 외운다
3. **교차 검증을 반드시 사용하라**: 일반화 성능을 추정하는 유일한 방법이다

실무 가이드

상황	증상	해결 방법
과소적합	학습 오류도 높고 테스트 오류도 높다	더 복잡한 모델 사용, 특성(feature) 추가
과적합	학습 오류는 낮은데 테스트 오류가 높다	더 단순한 모델 사용, 정규화, 데이터 추가
적절한 적합	학습 오류와 테스트 오류 모두 적절히 낮다	현재 모델 유지!

실행 방법

```
cd ■■■■/
python 01_bias_variance_tradeoff.py
```

필요 패키지: `numpy`, `matplotlib`, `scikit-learn`

실행 시간: 약 30~60초 (200개 데이터셋 × 15개 차수의 반복 학습)

출력 파일:

- `01_model_fits.png` — 다항 회귀 적합 결과 비교
- `01_bias_variance_tradeoff.png` — 편향-분산 트레이드오프 곡선
- `01_prediction_variability.png` — 예측 변동성 비교