03. 교차 검증 (Cross-Validation) 전략 비교 데모

개요

항목	내용
파일명	`03_cross_validation_demo.py`
주제	교차 검증 전략별 원리, 데이터 분할 패턴, 성능 추정 안정성 비교
핵심 라이브러리	NumPy, Matplotlib, scikit-learn
비교 전략	Hold-Out, K-Fold, Stratified K-Fold, Leave-One-Out (LOO)
생성 결과물	`03_cv_splits.png`, `03_variance_comparison.png`, `03_k_tradeoff.png`, `03_iris_cv_comparison.png`

먼저 알아야 할 것: 왜 교차 검증이 필요한가?

문제 상황: 내 모델이 얼마나 잘하는지 어떻게 알까?

모델을 만들었다. 학습 데이터에서 95% 정확도가 나왔다. **이 모델을 실제로 써도 될까?**

답: 알 수 없다. 학습 데이터에서의 성능은 **아무 의미가 없다.** 시험 문제를 미리 본 학생이 100점을 받는 것과 같다.

우리가 정말 알고 싶은 것은: **"이 모델이 아직 보지 못한 새로운 데이터에서도 잘 작동할까?"** 이다.

가장 단순한 방법: 데이터를 나누자

가장 직관적인 방법은 데이터를 **학습용**과 **테스트용**으로 나누는 것이다:

1. 전체 데이터 100개 중 80개로 모델을 학습
2. 나머지 20개로 성능을 테스트
3. 이 20개에서의 정확도가 "실제 성능"의 추정값

그런데 이 방법에는 심각한 문제가 있다:

- **어떤 20개를 테스트로 뽑느냐에 따라 결과가 크게 달라진다!**
- 운 좋게 쉬운 데이터가 테스트에 들어가면 → 성능이 높게 나옴
- 운 나쁘게 어려운 데이터가 테스트에 들어가면 → 성능이 낮게 나옴
- 한 번의 분할로 "이 모델의 정확도는 92%입니다"라고 보고하면, 이 숫자를 **신뢰할 수 없다**

교차 검증의 아이디어

"그러면 여러 번 나누어서 평균을 내면 되지 않을까?" → 이것이 바로 교차 검증이다!

교차 검증은 데이터를 여러 번 다르게 나누고, 매번 학습/평가를 반복하고, 그 결과의 **평균**을 최종 성능으로 보고한다. 이렇게 하면 "운에 따른 변동"을 줄일 수 있다.

4가지 교차 검증 전략 상세 설명

전략 1: Hold-Out (홀드아웃)

가장 단순한 방법이지만, 가장 불안정하다.

방법:

1. 데이터를 한 번만 학습/테스트로 나눈다 (보통 80:20 또는 70:30)
2. 한 번 학습하고, 한 번 평가한다
3. 끝!

비유: 수학 시험을 단 1회만 보고, 그 점수로 실력을 판단하는 것. 그 날 컨디션이 좋았거나 문제가 쉬웠을 수도 있는데, 한 번만 보고 판단하니 불안하다.

장점: 매우 빠르다 (1번만 학습하면 됨)

단점:

- 어떻게 나누느냐에 따라 결과가 크게 달라진다 (높은 분산)
- 데이터의 20%를 학습에 사용하지 않으므로 낭비

언제 사용? 데이터가 아주 많을 때 (100만 건 이상), 빠른 프로토타이핑할 때

전략 2: K-Fold (K-폴드 교차 검증)

교차 검증의 표준 방법.

방법:

1. 데이터를 **K개의 동일한 크기 조각(폴드)** 으로 나눈다
2. 1번째 폴드를 테스트, 나머지 K-1개를 학습 → 정확도 기록
3. 2번째 폴드를 테스트, 나머지 K-1개를 학습 → 정확도 기록
4. ...
5. K번째 폴드를 테스트, 나머지 K-1개를 학습 → 정확도 기록
6. K번의 정확도의 **평균** = 최종 성능 추정

K=5일 때 예시 (데이터 100개):

라운드	학습 데이터	테스트 데이터
1회차	폴드 2,3,4,5 (80개)	폴드 1 (20개)
2회차	폴드 1,3,4,5 (80개)	폴드 2 (20개)
3회차	폴드 1,2,4,5 (80개)	폴드 3 (20개)
4회차	폴드 1,2,3,5 (80개)	폴드 4 (20개)
5회차	폴드 1,2,3,4 (80개)	폴드 5 (20개)

비유: 수학 시험을 5번 보되, 매번 다른 문제 세트로 시험을 본다. 5번의 점수를 평균 내면 실력을 더 정확히 파악할 수 있다.

장점:

- 모든 데이터가 한 번씩은 테스트에 사용됨 → 데이터 낭비 없음
- 여러 번 평균하므로 Hold-Out보다 안정적

단점:

- K번 학습해야 하므로 K배 느림
- 클래스 비율이 폴드마다 다를 수 있음 (다음 전략에서 해결)

전략 3: Stratified K-Fold (층화 K-폴드)

실무에서 가장 많이 추천되는 방법. sklearn의 기본 설정이기도 하다.

문제: 만약 데이터에 양성 30개, 음성 70개가 있는데, 어떤 폴드에는 양성이 0개만 들어간다면? 그 폴드에서의 평가는 전혀 의미가 없다!

Stratified K-Fold의 해결책:

- K-Fold와 동일하되, **각 폴드에서 클래스 비율을 원본과 동일하게 유지**한다
- 원본에서 양성:음성 = 30:70이면, 모든 폴드에서도 약 30:70이 되도록 배분

비유: 남녀 비율이 4:6인 학교에서 반 편성을 할 때, 각 반의 남녀 비율도 4:6으로 맞추는 것. 이렇게 해야 각 반에서의 결과가 전체를 대표할 수 있다.

장점:

- 불균형 데이터에서도 안정적인 성능 추정
- 각 폴드가 전체 데이터의 축소판

단점:

- 분류 문제에서만 사용 가능 (회귀 문제에는 "클래스"가 없으므로)

언제 사용? 분류 문제에서는 **항상 이것을 기본으로 사용하라!**

전략 4: Leave-One-Out (LOO, 1개씩 빼기)

가장 극단적인 교차 검증.

방법:

1. 데이터가 N개일 때, **한 번에 1개만 테스트**로 빼고, 나머지 N-1개로 학습
2. 이것을 N번 반복 (모든 데이터가 한 번씩 테스트됨)
3. N번의 결과(맞음/틀림)의 평균 = 최종 성능

비유: 100명의 학생이 있을 때, 1명을 빼고 99명으로 모델을 만들어 그 1명을 예측. 이것을 100명 각각에 대해 반복.

장점:

- **거의 전체 데이터로 학습**하므로 편향이 가장 낮다
- 데이터가 매우 적을 때 유용 (10~50개 정도)

단점:

- **계산 비용이 엄청나다**: 데이터 N개 = N번 학습. 데이터가 10,000개면 10,000번 학습해야 함
- 각 평가가 1개 데이터에만 의존하므로 (맞음=1, 틀림=0), 분산이 높을 수 있다

언제 사용? 데이터가 매우 적을 때 (50개 이하)

전략 비교 요약

전략	학습 횟수	편향	안정성(분산)	속도	추천 상황
Hold-Out	1회	높음	불안정	매우 빠름	데이터 대용량
K-Fold (K=5)	5회	중간	안정적	보통	일반적 사용
Stratified K-Fold	5회	중간	매우 안정	보통	분류 문제 기본
LOO	N회	낮음	불안정 가능	매우 느림	데이터 소량

이 코드가 하는 일: 전체 흐름

```
[■■■ 1] 4■■ ■■■ ■■■■ ■■■ ■■■■ ■■■ → 03_cv_splits.png
[■■■ 2] ■ ■■■ 50■ ■■■■ ■■ ■■■ ■■ → 03_variance_comparison.png
[■■■ 3] K■■ ■■■■■ ■■-■■ ■■■■■■ ■■ → 03_k_tradeoff.png
[■■■ 4] ■■ Iris ■■■■■■ ■■■ ■■ ■■ → 03_iris_cv_comparison.png
```

결과물 분석

결과 1: 교차 검증 분할 패턴

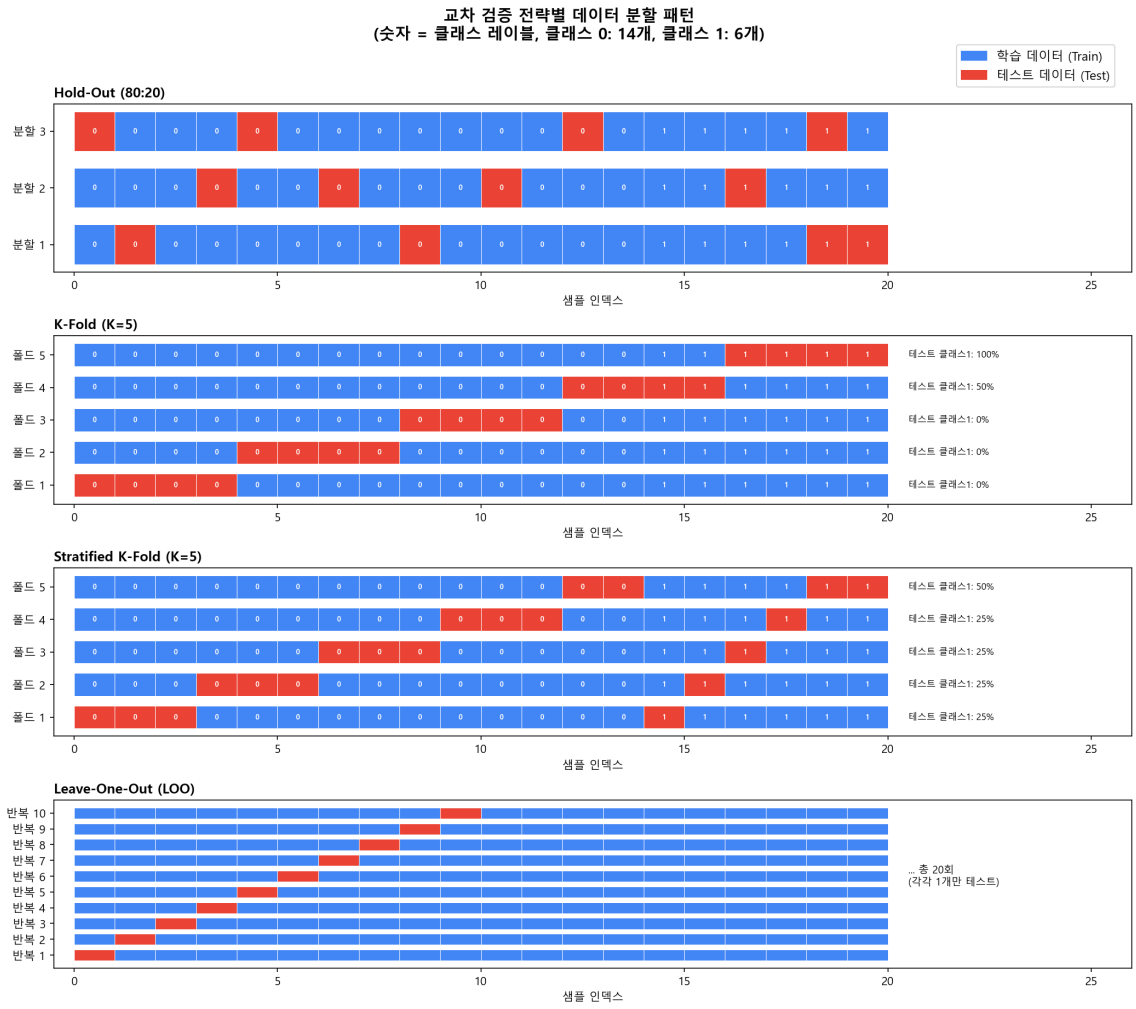

교차 검증 분할 패턴

이 그림을 읽는 법:

이 그림은 20개의 데이터(가로축의 각 칸)를 4가지 전략이 어떻게 학습(파란색)/테스트(빨간색)로 나누는지 보여준다. 각 칸 안의 숫자(0 또는 1)는 **클래스 레이블**이다.

중요: 이 데이터는 의도적으로 **불균형**이다 — 클래스 0이 14개, 클래스 1이 6개. 이 불균형이 있어야 Stratified K-Fold의 장점이 드러난다.

1행: Hold-Out (80:20)

- 3번의 서로 다른 랜덤 분할을 보여준다
- **핵심 관찰**: 매번 빨간색(테스트) 위치가 완전히 다르다!
- 분할 1에서 테스트에 클래스 1이 3개 들어갈 수도, 분할 2에서는 1개만 들어갈 수도 있다
- 이것이 Hold-Out의 **불안정성의 원인**이다

2행: K-Fold (K=5)

- 데이터를 5개 연속 블록으로 나누고, 돌아가면서 1블록씩 테스트에 사용
- 모든 데이터가 정확히 1번 테스트에 사용된다 → 데이터 낭비 없음
- **문제**: 오른쪽에 표시된 "테스트 클래스1" 비율을 보면, 폴드마다 클래스 비율이 다르다!
- 예를 들어, 폴드 1의 테스트에는 클래스 1이 0개이고, 폴드 5에는 3개일 수 있다

3행: Stratified K-Fold (K=5)

- K-Fold와 같은 원리이지만, **각 폴드의 클래스 비율을 원본(70:30)과 동일하게 유지**
- 오른쪽의 "테스트 클래스1" 비율을 보면, **모든 폴드에서 비슷한 비율**이다!
- 이것이 불균형 데이터에서 Stratified가 더 안정적인 이유

4행: Leave-One-Out (LOO)

- 한 번에 1개(빨간색)만 테스트, 나머지 19개(파란색)로 학습
- 총 20회 반복 (여기서는 10회만 표시)
- 학습 데이터가 거의 전체(19/20 = 95%)이므로 편향은 낮지만, 1개만으로 평가하므로 결과가 0 또는 1뿐

결과 2: 성능 추정 분산 비교

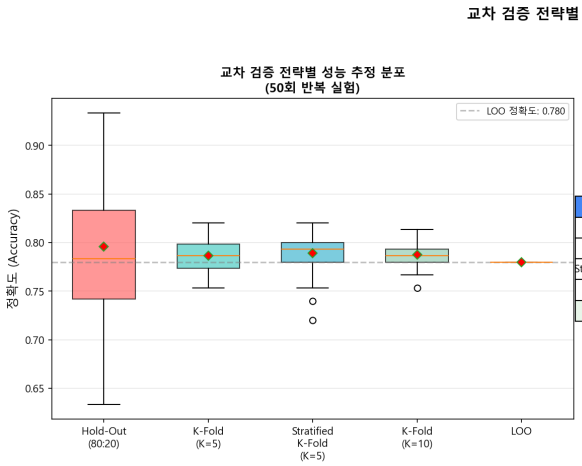

성능 추정 통계 요약
(초록 = 가장 낮은 분산)

전략	평균	표준편차	최소	최대	범위
Hold-Out (80:20)	0.7960	0.0642	0.6333	0.9333	0.3000
K-Fold (K=5)	0.7864	0.0150	0.7533	0.8200	0.0667
Stratified K-Fold (K=5)	0.7889	0.0196	0.7200	0.8200	0.1000
K-Fold (K=10)	0.7875	0.0118	0.7533	0.8133	0.0600
LOO	0.7800	0.0000	0.7800	0.7800	0.0000

분산 비교

이 그림을 읽는 법:

5가지 교차 검증 전략에 대해 **"같은 실험을 50번 반복하면 결과가 얼마나 달라지는가"** 를 보여준다.

왼쪽: 박스 플롯 (Box Plot)

박스 플롯 읽는 법을 먼저 알아야 한다:

- **상자의 윗변**: 상위 25% 경계 (Q3)
- **상자의 아랫변**: 하위 25% 경계 (Q1)
- **상자 안의 주황색 선**: 중앙값 (50번 중 25번째 값)
- **빨간 다이아몬드**: 평균값
- **수염(위아래 선)**: 전체 분포의 범위
- 상자가 **좁을수록 결과가 안정적**, 넓을수록 불안정

각 전략별 해석:

전략	상자 크기	해석
Hold-Out	**가장 넓다**	어떻게 나누느냐에 따라 정확도가 크게 변한다. 한 번은 88%, 다음은 93%... **매우 불안정**

전략	상자 크기	해석
K-Fold (K=5)	좁아짐	5번 평균하므로 안정화. 하지만 여전히 약간의 변동
Stratified K-Fold	더 좁음	클래스 비율까지 맞추므로 **가장 실용적으로 안정적**
K-Fold (K=10)	비슷하거나 더 좁음	10번 평균하므로 5-Fold보다 약간 더 안정
LOO	**점 하나**	결정적이므로 항상 같은 결과 (분산=0). 하지만 이것이 "정확하다"는 의미는 아님

오른쪽: 통계 요약 표

- 초록색으로 강조된 행이 **LOO를 제외하고 분산이 가장 낮은 전략**
- Hold-Out의 "범위"(최대-최소)가 가장 크다 → **절대 Hold-Out만으로 성능을 보고하지 마라!**

핵심 교훈: 논문이나 보고서에서 "이 모델의 정확도는 93%입니다"라고 쓸 때, 그 93%가 **얼마나 신뢰할 수 있는가**가 중요하다. Hold-Out으로 얻은 93%는 실제로 88~97% 사이 어딘가일 수 있지만, Stratified K-Fold로 얻은 93%는 92~94% 사이에서 안정적이다.

결과 3: K값에 따른 편향-분산 트레이드오프

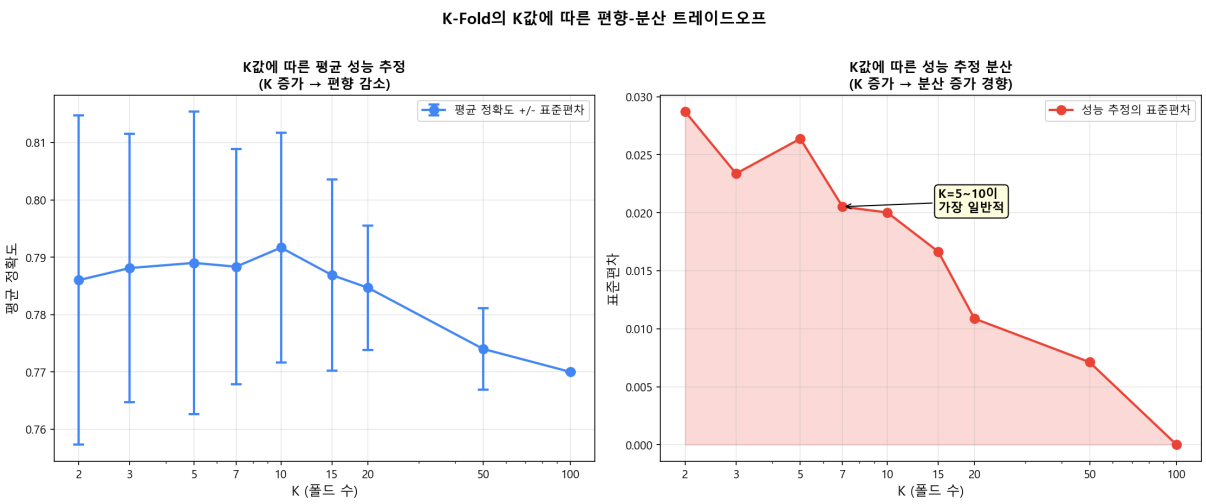

K값 트레이드오프

이 그림을 읽는 법:

K-Fold에서 **K값을 2부터 100(=LOO)까지 변화시키면** 성능 추정이 어떻게 달라지는지 보여준다.

왼쪽 패널 — 평균 정확도 (편향과 관련):

- **K가 작을 때 (K=2~3)**: 평균 정확도가 **낮게 나온다**
- 왜? K=2이면 데이터의 50%로만 학습 → 학습 데이터가 부족해 모델이 제대로 학습 못함
- 이것은 모델의 진짜 성능보다 **과소 추정**하는 것 = **높은 편향**
- 비유: 교과서의 절반만 읽고 시험 보면, 실력보다 점수가 낮게 나온다
- **K가 클수록**: 평균 정확도가 점점 **올라간다**
- K=10이면 90%로 학습 → 거의 전체 데이터를 사용하므로 모델이 잘 학습됨

- 진짜 성능에 **더 가까운 추정** = **낮은 편향**
- **K=100 (LOO)**: 99%의 데이터로 학습 → 편향이 가장 낮음

오른쪽 패널 — 표준편차 (안정성과 관련):

- **K가 작을 때**: 의외로 분산이 그리 높지 않다
- 왜? 폴드 간 학습 데이터가 서로 많이 다르므로, 각 폴드의 결과가 **독립적**이다
- **K가 중간 (5~10)**: 적절한 수준의 분산
- **K가 매우 클 때**: 분산이 증가할 수 있다
- 왜? K=100이면, 폴드 1의 학습 데이터와 폴드 2의 학습 데이터가 99개 중 98개 동일
- 거의 같은 데이터로 학습하므로 결과가 서로 **매우 비슷** → 독립성이 낮다

"K=5~10이 가장 일반적" 주석: 이 범위가 편향과 분산의 적절한 균형점이다.

실무 가이드:

K값	편향	분산	계산 비용	추천도
2~3	높음	낮음	빠름	비추천 (편향 너무 높음)
5	적절	적절	보통	추천 (sklearn 기본값)
10	낮음	적절	보통	추천 (더 정밀한 추정)
20+	매우 낮음	높을 수 있음	느림	특수한 경우만
N (LOO)	가장 낮음	높을 수 있음	매우 느림	데이터 극소량일 때만

결과 4: Iris 데이터셋 실전 예제

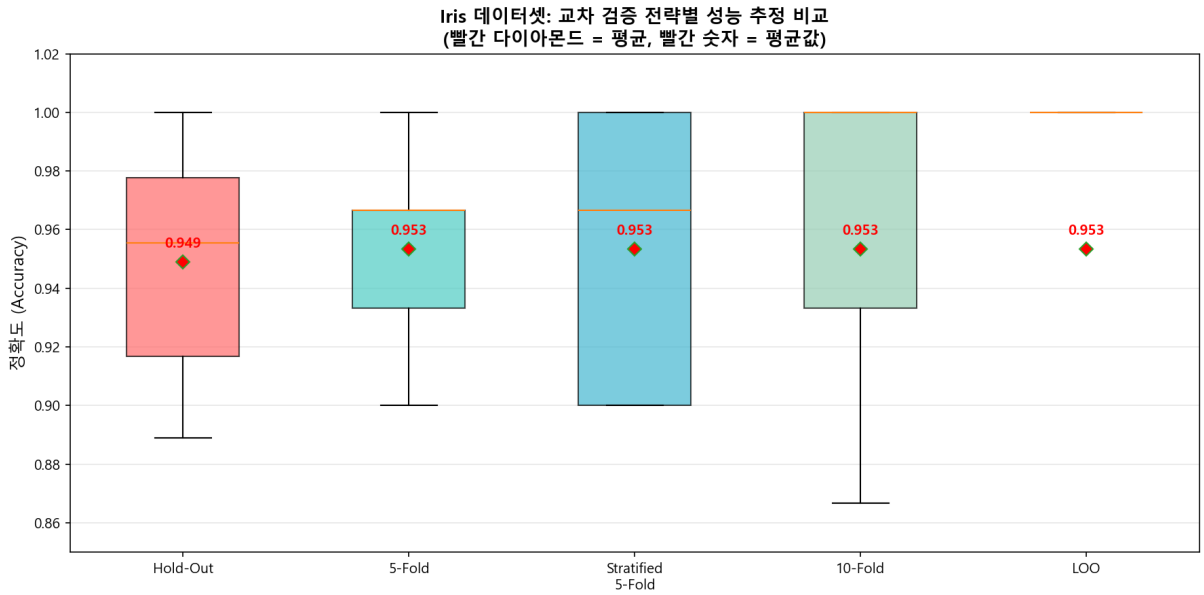

Iris CV 비교

이 그림을 읽는 법:

지금까지는 합성(가짜) 데이터로 실험했다면, 이제는 **실제 데이터(Iris)** 로 확인한다.

Iris 데이터셋이란?

- 붓꽃(Iris) 150송이의 꽃잎/꽃받침 길이와 너비 4가지를 측정한 데이터
- 3종류(Setosa, Versicolor, Virginica) 각 50개
- 머신러닝에서 가장 유명한 입문용 데이터셋

각 전략의 결과:

- **Hold-Out**: 상자가 가장 넓다 (분포가 넓다)
- 10번 반복했을 때 정확도가 약 91%~100%까지 변동
- "이 모델의 정확도는 95%입니다"라고 보고해도, 실제로는 91%~100% 사이 어딘가
- **신뢰성이 낮다**
- **5-Fold / Stratified 5-Fold**: 상자가 좁아진다
- 정확도 추정이 더 안정적
- 5개의 점(각 폴드의 정확도)이 보인다
- **10-Fold**: 10개의 점. 더 많은 평가로 인해 분포가 더 세밀하다
- **LOO**: 150개의 개별 결과(각각 0=틀림 또는 1=맞음)
- 평균은 다른 방법과 비슷하지만, 분포의 의미가 다르다 (이진값의 분포)

핵심 관찰:

- Iris는 비교적 "쉬운" 데이터이므로 모든 전략에서 높은 정확도(~96-97%)
- 그런데도 **Hold-Out의 변동성은 뚜렷** → "쉬운 데이터에서도 Hold-Out은 불안정하다"
- 어려운 데이터에서는 이 차이가 더 크게 벌어진다

핵심 정리: 교차 검증 전략 선택 가이드

초보자를 위한 3줄 요약

1. **분류 문제라면 Stratified K-Fold를 기본으로 사용하라** (K=5 또는 K=10)
2. **절대 Hold-Out만으로 최종 성능을 보고하지 마라** (운에 따라 크게 달라짐)
3. **데이터가 매우 적으면(50개 이하) LOO를 고려하라**

데이터 크기별 권장

데이터 크기	권장 전략	이유
대용량 (10,000개 이상)	Hold-Out 또는 3-Fold	데이터가 충분하므로 한 번 나눠도 안정적. 속도 중요
중간 (100~10,000개)	Stratified 5-Fold 또는 10-Fold	편향과 분산의 좋은 균형. 가장 범용적
소량 (50~100개)	Repeated Stratified K-Fold	K-Fold를 여러 번 반복하여 더 안정적으로
극소량 (50개 이하)	LOO	모든 데이터를 최대한 활용해야 함

데이터 유형별 권장

데이터 유형	권장 전략	이유
균형 분류 (각 클래스 비슷)	K-Fold (K=5~10)	클래스 비율이 균형이므로 기본 K-Fold 충분
불균형 분류 (한 클래스가 적음)	**Stratified K-Fold**	각 폴드의 클래스 비율 보장이 필수!
회귀 문제	K-Fold (K=5~10)	Stratified는 분류 전용 (클래스 개념이 없으므로)
시계열 데이터	Time Series Split	미래 데이터로 학습 → 과거 예측하면 안 됨. 시간 순서 존중 필수
그룹 데이터 (같은 환자의 여러 기록 등)	Group K-Fold	같은 그룹이 학습/테스트에 동시에 들어가면 데이터 누수!

sklearn에서의 사용법

```
from sklearn.model_selection import cross_val_score, StratifiedKFold

# ■■ ■■■■ ■■■ (■■■ = Stratified 5-Fold)
scores = cross_val_score(model, X, y, cv=5, scoring='accuracy')
print(f"■■■: {scores.mean():.3f} +/- {scores.std():.3f}")

# ■■■■■ Stratified K-Fold ■■
cv = StratifiedKFold(n_splits=10, shuffle=True, random_state=42)
scores = cross_val_score(model, X, y, cv=cv)
```

실행 방법

```
cd ■■■■/
python 03_cross_validation_demo.py
```

필요 패키지: `numpy`, `matplotlib`, `scikit-learn`

실행 시간: 약 30~90초 (LOO의 150회 반복이 주요 소요 시간)

출력 파일:

- `03_cv_splits.png` — 교차 검증 분할 패턴 시각화
- `03_variance_comparison.png` — 성능 추정 분산 비교 (박스 플롯 + 통계 표)
- `03_k_tradeoff.png` — K값에 따른 편향-분산 트레이드오프
- `03_iris_cv_comparison.png` — Iris 데이터셋 실전 CV 비교