04_Linear Regression 运行结果详细解析

授课教师: Prof. Jung, Minpo **课程**: Machine Learning **学期**: 2026 年度第 1 学期 **对象**: 博士课程（中国博士课程学生）

---

1. 数据加载及整体结构确认

```
      age  sex     bmi  children  smoker      charges
0      19    0  27.900         0       1  16884.92400
...
1337   61    0  29.070         0       1  29141.36030

[1338 rows x 6 columns]
```

解析

- **共 1338 名**保险投保人数据已正常加载。
- **6 个变量**: age（年龄）、sex（性别）、bmi（体质量指数）、children（子女数）、smoker（吸烟与否）、charges（保险理赔费用）
- **索引**: 从 0 到 1337（Python 默认索引）
- 第一条数据（索引 0）：19 岁，女性 (0)，BMI 27.9，无子女，吸烟者 (1) → 保险费 $16,884
- 最后一条数据（索引 1337）：61 岁，女性 (0)，BMI 29.07，无子女，吸烟者 (1) → 保险费 $29,141

---

2. 前 5 条数据确认 (head)

```
   age  sex     bmi  children  smoker      charges
0   19    0  27.900         0       1  16884.92400
1   18    1  33.770         1       0   1725.55230
2   28    1  33.000         3       0   4449.46200
3   33    1  22.705         0       0  21984.47061
4   32    1  28.880         0       0   3866.85520
```

解析

- **sex 编码**: 0 = 女性，1 = 男性（分类型 → 数值转换完成）
- **smoker 编码**: 0 = 非吸烟者，1 = 吸烟者
- 比较索引 0 号和 3 号可以发现有趣的模式:
  - 0 号: 19 岁，吸烟者 → $16,884
  - 3 号: 33 岁，非吸烟者 → $21,984
  - 虽然年龄大 14 岁，但非吸烟者 3 号的保险费更高 → 表明**除吸烟与否外，其他因素也在综合发挥作用**

---

3. 数据结构信息 (info)

```
RangeIndex: 1338 entries, 0 to 1337
Data columns (total 6 columns):
```

```
 #   Column    Non-Null Count  Dtype
---  ------    --------------  -----
 0   age       1338 non-null   int64
 1   sex       1338 non-null   int64
 2   bmi       1338 non-null   float64
 3   children  1338 non-null   int64
 4   smoker    1338 non-null   int64
 5   charges   1338 non-null   float64
dtypes: float64(2), int64(4)
memory usage: 62.8 KB
```

解析

- **完全没有缺失值 (Missing Value)** → 所有变量均为 1338 non-null
- 在实际工作中这种情况非常罕见，可以看出这是为教材预先清洗过的数据
- **数据类型 (Dtype)**:
  - `int64` (整数)：age、sex、children、smoker → sex 和 smoker 原本是分类型变量，但已编码为数值
  - `float64` (浮点数)：bmi、charges → 带小数点的连续型变量
- **内存使用量**: 62.8 KB → 非常小的数据集（实际工作中数 GB 以上也很常见）
- 无需额外的数据清洗或缺失值处理，可以直接进入建模阶段

---

4. 描述性统计量 (describe)

	age	sex	bmi	children	smoker	charges
count	1338.00	1338.00	1338.00	1338.00	1338.0	1338.00
mean	39.21	0.51	30.66	1.09	0.2	13270.42
std	14.05	0.50	6.10	1.21	0.4	12110.01
min	18.00	0.00	15.96	0.00	0.0	1121.87
25%	27.00	0.00	26.30	0.00	0.0	4740.29
50%	39.00	1.00	30.40	1.00	0.0	9382.03
75%	51.00	1.00	34.69	2.00	0.0	16639.91
max	64.00	1.00	53.13	5.00	1.0	63770.43

各变量详细解析

age（年龄）

统计量	值	含义
mean	39.21	平均年龄约 39 岁
std	14.05	标准差 14 岁 → 年龄分布较广
min	18.00	最小 18 岁（仅包含成年人）
50%	39.00	中位数 39 岁 → 与平均值几乎一致（暗示对称分布）
max	64.00	最大 64 岁

sex（性别）

统计量	值	含义
mean	0.51	男性 (1) 比例约 51% → 男女比例几乎均等

bmi（体质量指数）

统计量	值	含义
mean	30.66	WHO 标准 BMI 30 以上为"肥胖" → 平均值位于肥胖临界值
min	15.96	体重偏低水平
max	53.13	重度肥胖

children（子女数）

统计量	值	含义
mean	1.09	平均约 1 个子女
max	5.00	最多 5 个
75%	2.00	75% 的人子女在 2 个以下

smoker（吸烟与否）

统计量	值	含义
mean	0.20	吸烟者比例约 20% → **非吸烟者占 80%，占压倒性多数**

charges（保险理赔费用）—因变量

统计量	值	含义
mean	13,270.42	平均保险费约 $13,270
std	12,110.01	**标准差与平均值几乎相同** → 分布非常广（偏差大）
min	1,121.87	最低保险费约 $1,122
50%	9,382.03	中位数 $9,382 → **远低于平均值 ($13,270)** → 右偏分布 (right-skewed)
max	63,770.43	最高保险费约 $63,770 → 约为最低值的 57 倍

核心洞察：charges 的平均值 (13,270) > 中位数 (9,382)，因此可以看出少数高额理赔者拉高了平均值，呈**右偏 (right-skewed) 分布**。这很可能是由吸烟者群体的高保险费造成的。

---

5. 预测值 vs 实际值比较 (comparison)

```
           actual          pred
12      1826.84300   4765.249466
306    20177.67113   4957.730865
318     7421.19455   8298.988153
815     1877.92940   3078.811868
157    15518.18025  24165.956542
...
1015   12124.99240  11638.260006

[268 rows x 2 columns]
```

解析

- 这是对 268 个测试集样本的预测结果（占全部 1338 的 20%）
- 个别案例分析：

索引	实际值 (actual)	预测值 (pred)	误差	判定
12	\$1,827	\$4,765	+\$2,938	过高预测（2.6 倍）
306	\$20,178	\$4,958	-\$15,220	**严重过低预测**
318	\$7,421	\$8,299	+\$878	相对准确
815	\$1,878	\$3,079	+\$1,201	过高预测
157	\$15,518	\$24,166	+\$8,648	过高预测
1015	\$12,125	\$11,638	-\$487	**非常准确**

- **索引 306 号**特别值得关注：实际为 \$20,178 却预测为 \$4,958 → 此人可能是吸烟者，但模型未能正确捕捉
- **索引 1015 号**误差仅为 \$487，展示了非常准确的预测

---

6. 散点图可视化

```
plt.figure(figsize=(10,10))
sns.scatterplot(x='actual', y='pred', data=comparison)
```

解析

散点图中 **x 轴 = 实际值，y 轴 = 预测值。**

- **如果是完美模型**：所有点应落在 45 度对角线 (y = x) 上
- **实际结果解析**：
  - **低额保险费区间** (\$0~\$15,000)：点较好地聚集在对角线附近 → 预测良好
  - **中额保险费区间** (\$15,000~\$35,000)：点开始偏离对角线 → 过高/过低预测混合
  - **高额保险费区间** (\$35,000 以上)：点大幅分散 → 预测不稳定
- **出现 3 个聚类**的原因：吸烟者/非吸烟者群体之间保险费差异大。线性回归难以完美捕捉这种群体间的非线性差异。

---

7. RMSE (Root Mean Squared Error)

`5684.927776334484`

解析

- **RMSE = \$5,684.93**
- 这意味着"**预测值与实际值平均偏差约为 \$5,685**"
- 平均保险费为 \$13,270，因此 RMSE/平均值 = 5,685/13,270 = **约 42.8%** → 误差相当大
- RMSE 没有绝对的好/坏标准，主要用于**与其他模型的相对比较**
- 后续应用 Ridge、Lasso、Random Forest、XGBoost 等方法来降低此 RMSE 将成为目标

RMSE 计算过程

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

1. 对每个数据计算（实际值 - 预测值）的差
2. 对差值进行平方（消除符号 + 对大误差施加惩罚）
3. 计算平方值的平均（MSE）
4. 对平均值取平方根（恢复到原始数据尺度）

---

8. R^2 (决定系数)

`0.7368220127747351`

解析

- **R^2 = 0.7368 (约 73.7%)**
- 这意味着"**5 个自变量 (age、sex、bmi、children、smoker) 解释了因变量 (charges) 变动的约 73.7%**"

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

- **SST** (Sum of Squares Total)：因变量的总变动量（相对于平均值）
- **SSR** (Sum of Squares Regression)：模型解释的变动量
- **SSE** (Sum of Squares Error)：模型未能解释的变动量（误差）

R^2 范围	解析
0.9 以上	非常优秀的模型
0.7 ~ 0.9	良好的模型
0.5 ~ 0.7	一般
0.5 以下	解释力不足

- 我们模型的 $R^2 = 0.74$ 属于**"良好"水平**
- **剩余的 26.3%** 由当前模型中未包含的因素来解释：
  - 基础疾病有无、居住地区、职业、运动习惯等
  - 或变量间的非线性关系（例如：吸烟者的 BMI 效应可能与非吸烟者不同）

---

9. 回归系数 (Coefficients)

```
age           264.799803
sex            17.344661
bmi           297.514806
children      469.339602
smoker      23469.280173
dtype: float64
```

各变量影响力解析

变量	系数	解析
smoker	**+23,469.28**	**影响最大。**吸烟者 (1) 相比非吸烟者 (0) 保险费高约 $23,469
children	+469.34	每增加 1 个子女，保险费增加约 $469
bmi	+297.51	BMI 每增加 1，保险费增加约 $298
age	+264.80	年龄每增加 1 岁，保险费增加约 $265
sex	+17.34	男性 (1) 相比女性 (0) 高约 $17 → **实际上影响微乎其微**

核心洞察

1. **吸烟 (smoker) 是压倒性的首要因素**：系数为 23,469，比其他变量大数十至数百倍。仅吸烟与否一项就是保险费最大的决定因素。
2. **性别 (sex) 几乎无意义**：系数仅为 17，实际影响可以忽略。相比性别，健康相关变量对保险费重要得多。
3. **BMI 和年龄影响相近**：分别为 298 和 265，影响程度相似。
4. **子女数也有显著影响**：每增加 1 个子女约增加 $469 → 反映了根据受抚养人数确定保险费的机制。

---

10. 截距 (Intercept)

```
-11576.999976112374
```

解析

- **截距 (intercept) = -$11,577**
- 这表示公式中**所有自变量为 0 时的 charges 值**
- 实际上不存在”0 岁、女性、BMI 为 0、无子女、非吸烟者”这样的人，因此与其赋予截距现实意义，不如将其理解为**数学上的校正值**更为恰当
- 截距为负的原因：由于其他系数之和为较大的正数，截距需要为负数才能使整体预测值落在合理范围内

---

11. 最终预测公式

$charges = 264.80 \times age + 17.34 \times sex + 297.51 \times bmi + 469.34 \times children + 23469.28 \times smoker - 11577.00$

预测示例

30 岁，男性，BMI 25，1 个子女，非吸烟者的预测保险费：

$$\begin{aligned} charges &= 264.80 \times 30 + 17.34 \times 1 + 297.51 \times 25 + 469.34 \times 1 + 23469.28 \times 0 - 11577.00 \\ &= 7944.00 + 17.34 + 7437.75 + 469.34 + 0 - 11577.00 \\ &= \$4,291.43 \end{aligned}$$

同等条件的吸烟者：

$$charges = 4291.43 + 23469.28 = \$27,760.71$$

→ 仅凭吸烟与否一项，保险费就相差**约 6.5 倍**！

---

12. 综合评价

模型性能总结

指标	值	评价
RMSE	\$5,684.93	相对于平均保险费约 43% 的误差
R^2	0.7368	良好（73.7% 解释力）

模型的优势

- 解释性非常直观：可以定量把握各变量对保险费的影响
- 训练速度非常快
- 明确捕捉到吸烟是保险费的核心决定因素

模型的局限

- 对吸烟者内部的精细预测不足（未捕捉非线性关系）
- 由于 charges 呈右偏 (right-skewed) 分布，在高额保险费区间预测误差增大
- 未能考虑交互效应 (interaction effect)（例如：吸烟者的 BMI 效应可能更大）

改进方向

1. **对数变换**：对 charges 取 log 使分布正态化
2. **添加交互项**：添加 smoker × bmi 等交互作用项
3. **非线性模型**：使用决策树、随机森林、XGBoost 等捕捉非线性关系
4. **正则化技术**：通过 Ridge、Lasso、Elastic Net 提升泛化性能